

Estudio de Caso sobre Métodos de Aprendizaje No Supervisado: Análisis, Modelado y Evaluación de Técnicas de Reducción de Dimensionalidad y Agrupamiento

David Núñez Franco

Angel Leiva Abarca

Billy Cordero Porras

Marzo 2026

Resumen

Los métodos no supervisados constituyen una base importante para explorar conjuntos de datos sin etiquetas previas, ya que permiten identificar patrones, reducir dimensionalidad y formar grupos con características similares. En este laboratorio se analizó el conjunto de datos BankChurners mediante una estrategia exploratoria que integró preprocesamiento, Análisis de Componentes Principales (ACP), Agrupamiento Jerárquico Aglomerativo (HAC), K-medias y técnicas de proyección no lineal como T-SNE y UMAP. El objetivo fue comparar el comportamiento de estos métodos bajo distintos esquemas de escalamiento y evaluar su utilidad para describir la estructura de los datos. Los resultados evidencian que la combinación de reducción de dimensionalidad, agrupamiento y visualización facilita una interpretación más clara de los perfiles presentes en la población analizada.

Palabras clave: aprendizaje no supervisado, ACP, HAC, K-medias, T-SNE, UMAP.

1. Introducción

Los métodos no supervisados permiten analizar datos sin etiquetas previas, identificando patrones y estructuras ocultas. Entre estos, destacan el Análisis de Componentes Principales

(ACP) y el Agrupamiento Jerárquico Aglomerativo (HAC), ampliamente utilizados en la exploración y comprensión de datos.

El ACP es una técnica de reducción de dimensionalidad que transforma variables correlacionadas en un conjunto de componentes principales no correlacionados, ordenados según la varianza que explican. Su fundamento se basa en el análisis de la matriz de covarianza o correlación, utilizando autovalores y autovectores. Esta técnica facilita la visualización, la detección de patrones y el preprocesamiento de datos (Lozares Colina & López Roldán, 1991).

Por su parte, el HAC es un método de agrupamiento que construye una jerarquía de clústeres mediante fusiones sucesivas basadas en medidas de distancia y criterios de enlace. El resultado se representa mediante un dendrograma, el cual permite interpretar las relaciones entre observaciones y determinar el número adecuado de grupos (Dhulipala et al., 2021).

Ambas técnicas son complementarias: el ACP puede emplearse como paso previo al clustering para mejorar la calidad de los agrupamientos, mientras que el HAC permite analizar la estructura de similitud entre los datos.

2. Mapa conceptual




Figura 1: Mapa conceptual resumido sobre Análisis de Componentes Principales (ACP) y Agrupamiento Jerárquico Aglomerativo (HAC).

3. Otros métodos no supervisados

Además de las técnicas previamente descritas, existen otros métodos ampliamente utilizados en el aprendizaje no supervisado, como el Agrupamiento por Centroides (K-medias) y

técnicas modernas de reducción de dimensionalidad como T-SNE y UMAP. Estos métodos permiten segmentar datos y visualizar estructuras complejas de manera eficiente.

3.1. Mapa conceptual




Figura 2: Mapa conceptual de K-medias, T-SNE y UMAP

3.2. Definiciones

El método de K-medias es un algoritmo de agrupamiento que divide un conjunto de datos en K clústeres, donde cada observación pertenece al grupo con el centroide más cercano. Su objetivo es minimizar la variabilidad interna de cada grupo, lo que lo convierte en uno de los métodos más simples y eficientes para segmentación de datos.

Por otro lado, T-SNE (t-Distributed Stochastic Neighbor Embedding) es una técnica de reducción de dimensionalidad no lineal que se utiliza principalmente para visualizar datos de alta dimensión en espacios de dos o tres dimensiones, preservando relaciones de proximidad entre puntos.

Finalmente, UMAP (Uniform Manifold Approximation and Projection) es un método más reciente que también reduce la dimensionalidad de los datos, pero con mejor conservación de la estructura global y mayor eficiencia computacional en comparación con T-SNE.

4. Análisis de Componentes Principales (ACP)

4.1. Preparación de los datos

El dataset *BankChurners* contiene 810 observaciones y 15 variables (10 numéricas, 5 categóricas). No se detectaron valores nulos ni duplicados. Para el ACP se seleccionaron las 10 variables numéricas: *Customer_Age*, *Dependent_count*, *Months_on_book*, *Total_Relationship_Count*, *Months_Inactive_12_mon*, *Contacts_Count_12_mon*, *Credit_Limit*, *Total_Revolving_Bal*, *Total_Trans_Amt* y *Total_Trans_Ct*.

La matriz de correlación reveló asociaciones relevantes: *Customer_Age* y *Months_on_book* ($r = 0,79$), así como *Total_Trans_Amt* y *Total_Trans_Ct* ($r = 0,81$), lo cual justifica la aplicación del ACP como método de reducción de redundancia. Los boxplots evidenciaron valores atípicos en *Credit_Limit* y *Total_Trans_Amt*, aspecto determinante para la selección del escalamiento.




Figura 3: Matriz de correlación de las variables numéricas del dataset *BankChurners*.

4.2. Configuración estándar

Conforme al ACP sobre Variables Reducidas descrito por Lozares Colina & López Roldán (1991), las variables fueron centradas y estandarizadas mediante **StandardScaler** (media = 0, desviación estándar = 1), lo que equivale a operar sobre la matriz de correlaciones. Se ajustó un PCA con las 10 componentes posibles. La Tabla 1 presenta los valores propios obtenidos.

Cuadro 1: Valores propios y varianza explicada (StandardScaler).

Componente	Eigenvalue	% Varianza	% Acumulado
CP0	2.152	21.50	21.50
CP1	1.804	18.02	39.51
CP2	1.125	11.24	50.75
CP3	1.080	10.79	61.54
CP4	0.995	9.94	71.48
CP5	0.883	8.82	80.30

La regla de Kaiser identifica 4 componentes con eigenvalue > 1 , que acumulan el 61.54 % de la varianza total. El *scree plot* (Figura 4) muestra una caída pronunciada después de CP1, con un codo entre CP2 y CP4.




Figura 4: *Scree plot* con línea de Kaiser para la configuración estándar.

El círculo de correlación (Figura 5) muestra que **Total_Trans_Amt** y **Total_Trans_Ct** se alinean fuertemente con CP0, mientras que **Customer_Age** y **Months_on_book** dominan CP1.




Figura 5: Plano principal y círculo de correlación (CP0–CP1) con **StandardScaler**.

4.3. Variaciones de configuración

Se implementaron cinco variaciones para evaluar la sensibilidad del ACP a decisiones metodológicas:

1. **MinMaxScaler [0,1]:** Escala sin eliminar asimetría ni outliers. Con 4 componentes retiene 67.13 %, pero el $\cos^2$ promedio (0.54) indica menor calidad de representación individual.
2. **RobustScaler:** Centra por mediana y escala por rango intercuartílico (IQR), mitigando la influencia de valores atípicos. Con 4 componentes retiene **71.36 %**, el mayor entre los modelos con variables numéricas.
3. **Criterio de codo (3 componentes):** Retiene solo 50.75 % de la varianza, por debajo del umbral recomendado del 60 %. La pérdida de CP3 afecta la representación de `Dependent_count` y `Credit_Limit`.
4. **Sin estandarizar:** Las variables de mayor escala (`Credit_Limit`, `Total_Trans_Amt`) acaparan el 99.28 % en solo 2 componentes, confirmando la advertencia de Lozares Colina & López Roldán (1991) sobre la distorsión del ACP Canónico cuando las variables difieren en escala.
5. **Con variables categóricas (dummies):** El espacio se expande a 26 variables. Kaiser retiene 14 componentes (79.53 %), pero la fragmentación deteriora la interpretabilidad: cada componente captura entre 4 % y 10 %.

4.4. Comparación y selección del mejor modelo

La Tabla 2 sintetiza el desempeño de los seis modelos evaluados.

Cuadro 2: Comparación de configuraciones de PCA.

Modelo	Comp.	% Var. Acum.	$\cos^2$ prom.	λ_1
Estándar (Kaiser)	4	61.54	0.615	2.15
MinMaxScaler	4	67.13	0.539	0.12
RobustScaler	4	71.36	0.591	2.36
Estándar (Codo)	3	50.75	0.508	2.15
Sin estandarizar	4	100.0	0.422	$7,5 \times 10^7$
Con dummies	14	79.53	0.795	2.60




Figura 6: Varianza acumulada comparativa entre configuraciones.

El modelo seleccionado es el **PCA con RobustScaler y 4 componentes** (regla de Kaiser), por las siguientes razones: (1) alcanza la mayor varianza explicada entre los modelos válidos (71.36 %); (2) su escalamiento basado en mediana e IQR mitiga la influencia de los valores atípicos detectados en *Credit_Limit* y *Total_Trans_Amt*; (3) mantiene un $\cos^2$ promedio competitivo (0.591); y (4) conserva la parsimonia con solo 4 componentes sobre 10 variables numéricas.




Figura 7: Eigenvalues: StandardScaler vs. RobustScaler.

4.5. Análisis del modelo seleccionado

4.5.1. Correlaciones variables-componentes

La Tabla 3 presenta las correlaciones entre las variables originales y las cuatro componentes retenidas.

Cuadro 3: Correlaciones variables-componentes del modelo RobustScaler.

Variable	CP0	CP1	CP2	CP3
Customer_Age	-0,109	0,877	-0,137	0,011
Dependent_count	0,098	-0,127	0,101	-0,121
Months_on_book	-0,105	0,954	-0,132	0,030
Total_Relationship_Count	-0,445	-0,108	0,087	-0,091
Months_Inactive_12_mon	0,032	0,092	0,202	0,617
Contacts_Count_12_mon	-0,234	-0,005	0,568	0,606
Credit_Limit	0,328	0,179	0,807	-0,434
Total_Revolving_Bal	0,157	0,111	0,021	-0,069
Total_Trans_Amt	0,969	0,026	-0,082	0,146
Total_Trans_Ct	0,832	-0,022	-0,156	0,123

4.5.2. Interpretación de las componentes

- **CP0 — Actividad transaccional (27.95 %):** Dominada por Total_Trans_Amt ($r = 0,97$) y Total_Trans_Ct ($r = 0,83$), con contribución negativa de Total_Relationship_Count ($r = -0,44$). Representa la intensidad transaccional: valores altos identifican clientes con alto volumen de operaciones pero relativamente pocos productos bancarios.
- **CP1 — Antigüedad del cliente (15.98 %):** Asociada a Months_on_book ($r = 0,95$) y Customer_Age ($r = 0,88$). Captura el ciclo de vida del cliente en la entidad bancaria.

- **CP2 — Capacidad crediticia (15.01 %):** Correlacionada con **Credit_Limit** ($r = 0,81$) y **Contacts_Count_12_mon** ($r = 0,57$). Refleja perfiles de alto límite crediticio con interacción activa con el banco.
- **CP3 — Inactividad y contacto (12.43 %):** Combina **Months_Inactive_12_mon** ($r = 0,62$) y **Contacts_Count_12_mon** ($r = 0,61$) con contribución negativa de **Credit_Limit** ($r = -0,43$). Sugiere un perfil de clientes inactivos con bajo crédito que mantienen contacto con la entidad, posiblemente en riesgo de abandono.




Figura 8: Círculos de correlación del modelo RobustScaler en los tres planos factoriales.




Figura 9: Biplots del modelo RobustScaler (CP0-CP1, CP0-CP2, CP1-CP2).

4.5.3. Calidad de representación

Las variables mejor representadas en el espacio de 4 componentes son **Total_Trans_Amt** ($\cos^2 = 0,97$), **Months_on_book** ($\cos^2 = 0,94$), **Customer_Age** ($\cos^2 = 0,80$) y **Total_Trans_Ct** ($\cos^2 = 0,73$). En contraste, **Dependent_count** ($\cos^2 = 0,05$) y **Total_Revolving_Bal** ($\cos^2 = 0,04$) presentan representación deficiente, indicando que su variabilidad no se asocia linealmente con las principales fuentes de variación del dataset.




Figura 10: Calidad de representación ($\cos^2$) por variable en el modelo RobustScaler.




Figura 11: Contribución de cada variable a las cuatro componentes retenidas.

4.6. Síntesis

El ACP con RobustScaler y 4 componentes (Kaiser) logra reducir 10 variables a un espacio de 4 dimensiones que retiene el 71.36 % de la varianza total, superando la configuración estándar (61.54 %). Las componentes obtenidas describen dimensiones interpretables del comportamiento bancario: actividad transaccional, antigüedad, capacidad crediticia e inactividad. Estos resultados constituyen un insumo directo para las etapas posteriores de agrupamiento (HAC, *K*-medias), donde las componentes principales servirán como entrada al proceso de *clustering*.

5. Análisis de Clustering Jerárquico (HAC)

5.1. Configuración estándar

Se aplicó el algoritmo de clustering jerárquico (HAC) utilizando datos estandarizados mediante *StandardScaler*. Se evaluaron distintos métodos de enlace, específicamente: Ward, Average, Single y Complete.

A partir de los dendrogramas obtenidos, se observa que el método **Ward** presenta agrupaciones más claras y balanceadas. Por otro lado, los métodos *Single* y *Average* evidencian el efecto de encadenamiento, generando clusters poco definidos. El método *Complete* mejora la separación respecto a los anteriores, pero no alcanza la claridad del método Ward.




Figura 12: dendrograma standard Metodo Ward

Por lo tanto, el método Ward se considera el más adecuado en la configuración estándar.

5.2. Variación con RobustScaler

Se aplicó HAC utilizando *RobustScaler*, el cual es menos sensible a valores atípicos. Esta transformación permitió obtener clusters más estables y una mejor separación entre los grupos en comparación con el escalado estándar.

El método Ward nuevamente destacó por generar clusters compactos y bien definidos, confirmando su robustez frente a diferentes tipos de preprocesamiento.




Figura 13: dendrograma robust Método Ward

Esto evidencia que el uso de escalamiento robusto mejora la calidad del clustering cuando existen posibles valores atípicos en los datos.

5.3. HAC sobre Análisis de Componentes Principales (ACP)

Se aplicó HAC sobre los datos transformados mediante ACP, utilizando las componentes principales obtenidas previamente. Esta transformación permitió reducir la dimensionalidad del conjunto de datos, eliminando redundancias y ruido.

Como resultado, los dendrogramas obtenidos presentan una estructura más clara, facilitando la identificación de grupos bien diferenciados. Además, se observa una mejora en la separación visual de los clusters.




Figura 14: dendrograma pca

El método Ward aplicado sobre los datos transformados con ACP produce las agrupaciones más definidas.

5.4. Selección del mejor modelo

Se compararon las tres configuraciones evaluadas:

- HAC con StandardScaler
- HAC con RobustScaler
- HAC sobre datos transformados con ACP

Se determinó que el mejor modelo corresponde a **HAC con método Ward aplicado sobre datos transformados mediante ACP**, debido a que presenta una mejor separación de clusters y mayor claridad en la estructura jerárquica.

5.5. Análisis del modelo seleccionado

A partir del dendrograma, se identifican aproximadamente tres clusters principales.




Figura 15: dendrograma final clusters

5.5.1. Interpretación de clusters

Cluster 1: Clientes activos

- Altos valores en *Total_Trans_Amt* y *Total_Trans_Ct*
- Representan clientes con alto uso de servicios

Cluster 2: Clientes de bajo uso

- Bajos valores en transacciones
- Posibles clientes en riesgo de abandono

Cluster 3: Clientes intermedios

- Valores moderados en la mayoría de variables
- Representan un comportamiento promedio

5.6. Síntesis

El uso de HAC con el método Ward sobre datos reducidos mediante ACP permitió obtener agrupaciones más claras, compactas y fácilmente interpretables. Este enfoque mejora el desempeño del clustering al reducir la dimensionalidad, eliminar ruido y facilitar la identificación de patrones en los datos.

El método Ward fue seleccionado debido a su capacidad de minimizar la varianza intra-cluster, generando grupos más homogéneos y bien definidos.

6. Análisis de centroides con K -medias

6.1. Preparación de los datos

Para el análisis de centroides se utilizaron las 11 variables numéricas empleadas en el experimento: `ID`, `Customer_Age`, `Dependent_count`, `Months_on_book`, `Total_Relationship_Count`, `Months_Inactive_12_mon`, `Contacts_Count_12_mon`, `Credit_Limit`, `Total_Revolving_Bal`, `Total_Trans_Amt` y `Total_Trans_Ct`. No se detectaron valores nulos en este subconjunto, por lo que el punto de comparación entre modelos quedó determinado por el tipo de escalamiento aplicado y, en una de las variantes, por la eliminación de valores atípicos.

A diferencia del ACP, donde el objetivo principal era reducir dimensionalidad y resumir la estructura de variación, en K -medias el foco es particionar las observaciones en grupos compactos y separados, minimizando la suma de cuadrados intra-clúster. Por ello, la evaluación de modelos se basó principalmente en el coeficiente de *silhouette* y, de forma complementaria, en la inercia.

6.2. Configuración estándar

La configuración estándar se definió con las siguientes decisiones metodológicas: (1) estandarización de las variables con `StandardScaler`; (2) inicialización `k-means++`; (3) múltiples inicializaciones (`n_init`) para reducir dependencia de la semilla; y (4) selección automática del número de clústeres K en el rango $2 \leq K \leq 8$ utilizando como criterio principal el máximo valor de *silhouette*.

Esta configuración se justifica porque K -medias minimiza distancias cuadráticas, por lo que variables con escalas mayores pueden dominar la formación de los centroides si no son previamente normalizadas. Asimismo, la inicialización `k-means++` mejora la estabilidad y la convergencia del algoritmo respecto a selecciones completamente aleatorias.

6.3. Variaciones de configuración

Se implementaron cuatro variaciones adicionales sobre la configuración base:

1. **Sin escalar:** Se aplicó K -medias directamente sobre las variables originales. Esta variación permite evidenciar el efecto de la escala en la construcción de los centroides.
2. **MinMaxScaler:** Las variables fueron reescaladas al intervalo $[0, 1]$. Esta opción preserva relaciones relativas entre valores extremos, aunque puede seguir siendo sensible a atípicos.

3. **RobustScaler:** Se centraron las variables por mediana y se escalaron mediante el rango intercuartílico. Esta configuración busca reducir la influencia de observaciones extremas en la ubicación de los centroides.
4. **StandardScaler sin outliers:** Se eliminó un subconjunto de observaciones atípicas con base en $|z| > 3$ y posteriormente se aplicó **StandardScaler**. La intención fue evaluar si una limpieza adicional mejora la cohesión y separación de los grupos.

6.4. Comparación y selección del mejor modelo

La Tabla 4 resume la comparación entre la configuración estándar y las variaciones evaluadas. El criterio principal de selección fue el valor del coeficiente de *silhouette*; en caso de resultados cercanos, se consideró la inercia como criterio secundario de parsimonia interna.

Cuadro 4: Comparación de configuraciones de K -medias.

Modelo	Obs.	K óptimo	Silhouette	Inercia
Estándar (StandardScaler)	810	2	0.2363	7773.0713
Sin Escalar	810	2	0.8640	$9,6844 \times 10^{16}$
MinMaxScaler	810	3	0.1573	389.3925
RobustScaler	810	2	0.3452	5714.3343
StandardScaler sin outliers	732	6	0.1200	5283.8302




Figura 16: Comparación del coeficiente de *silhouette* entre las configuraciones de K -medias evaluadas.

En términos estrictamente métricos, el mejor modelo fue **Sin Escalar**, debido a que presentó el mayor valor de *silhouette* (0,8640), muy por encima del resto de configuraciones. No

obstante, la inspección posterior de los centroides muestra que la partición quedó fuertemente influida por la variable ID, que no representa comportamiento bancario sino un identificador. Por tanto, el modelo se reporta aquí como el ganador del experimento automático, aunque su interpretación sustantiva debe hacerse con cautela.

6.5. Selección del número de clústeres

Para el modelo ganador, se analizó el comportamiento de la inercia y del coeficiente de *silhouette* en distintos valores de K . La Figura ?? muestra ambos criterios de forma complementaria: la inercia decrece conforme aumenta el número de grupos, mientras que *silhouette* permite identificar el valor de K con mejor equilibrio entre compacidad y separación.




Figura 17: Curvas de inercia y *silhouette* para el modelo de K -medias seleccionado.

Con base en estas evidencias, se seleccionó $K = 2$, valor que ofrece la mejor calidad de agrupamiento dentro del rango evaluado. En efecto, para $K = 2$ se obtuvo una inercia de $9,6844 \times 10^{16}$ y un *silhouette* de 0,8640; a partir de $K = 3$ el *silhouette* disminuyó de forma sostenida (0.8395, 0.8115, 0.5987, 0.6203, 0.6189 y 0.6311 para $K = 3, \dots, 8$).

6.6. Análisis del modelo seleccionado

6.6.1. Centroides del modelo

La Tabla 5 presenta los centroides del modelo seleccionado en la escala original de las variables, lo cual permite una interpretación directa de los perfiles promedio de cada clúster.

Cuadro 5: Centroides del mejor modelo de K -medias en escala original.

Cluster	ID	Customer	Age	Dependent_count	Months_on_book	Total_Relationship_Count	Months_Inactive_12_mon	Contacts_Count_12_mon	Credit_Limit	Total_Revolving_Bal	Total_Trans_Amt	Total_Trans_Ct
Cluster 0	715044652.2857	46.6446	2.2143	35.6946	3.7429	2.3161	2.3982	8433.3955	1165.8304	4346.7804	63.9857	
Cluster 1	79022155.3000	45.7640	2.4400	36.2040	3.9080	2.3520	2.5080	7428.6200	1138.1000	4341.3920	65.0080	

6.6.2. Resumen descriptivo por clúster

La segmentación obtenida se complementa con el tamaño de cada grupo y los promedios observados en las variables originales. Esto permite identificar si existen clústeres equilibrados o si alguno concentra perfiles minoritarios pero diferenciados.

Cuadro 6: Resumen descriptivo por clúster del mejor modelo.

Cluster	n	ID	Customer	Age	Dependent	count	Months	on book	Total	Relationship	Count	Months	Inactive	12 mon	Credit	Limit	Total	Revolving	Bal	Total	Trans	Amt	Total	Trans	Ct
Cluster 0	560	715044652.2857	46.6446	2.2143	35.6946	3.7429	2.3161	2.3982	8433.3955	1165.8304	4346.7804	63.9857													
Cluster 1	250	790222155.3000	45.7640	2.4400	36.2040	3.9080	2.3520	2.5080	7428.6200	1138.1000	4341.3920	65.0080													

Se observa que el **Cluster 0** concentra la mayor parte de los casos ($n = 560$; 69.1%), mientras que el **Cluster 1** agrupa 250 observaciones (30.9%). Sin embargo, salvo por ID y Credit_Limit, las diferencias promedio entre clústeres son relativamente pequeñas.

6.6.3. Variables más discriminatorias

Para interpretar la segmentación, se calcularon las variables con mayor rango entre centroides, es decir, aquellas cuyos valores promedio difieren más entre los grupos. Estas variables permiten identificar qué dimensiones explican mejor la separación observada.

Cuadro 7: Variables con mayor capacidad discriminatoria entre centroides.

Variable	Rango entre centroides
ID	75177503.0143
Credit_Limit	1004.7755
Total_Revolving_Bal	27.7304
Total_Trans_Amt	5.3884
Total_Trans_Ct	1.0223

La tabla confirma que la variable dominante en la separación es ID, seguida a gran distancia por Credit_Limit. Este hallazgo refuerza que el agrupamiento obtenido no está principalmente gobernado por diferencias de comportamiento bancario, sino por una variable identificadora de gran escala.

6.6.4. Visualización de los clústeres

Aunque el modelo se ajustó sobre el espacio de variables originales, para visualizar la segmentación se proyectaron las observaciones sobre dos componentes principales. La Figura ?? permite observar la distribución de los individuos, la separación relativa de los grupos y la ubicación de sus centroides.




Figura 18: Proyección de los clústeres del mejor modelo de K -medias sobre dos componentes principales.

Adicionalmente, la Figura ?? compara los perfiles de los centroides en las variables más discriminatorias, facilitando la interpretación sustantiva de los grupos encontrados.




Figura 19: Comparación de perfiles de centroides en las variables más discriminatorias.

6.6.5. Interpretación de los clústeres

Con base en los centroides y en las variables discriminatorias, los dos clústeres pueden describirse de la siguiente manera:

- **Cluster 0 — Registros con ID menor y mayor límite crediticio promedio:**
agrupa 560 observaciones y se caracteriza por un valor promedio menor de ID, un `Credit_Limit` más alto, y valores ligeramente menores en `Dependent_count`, `Total_Relationship_Count`, `Contacts_Count_12_mon` y `Total_Trans_Ct`.
- **Cluster 1 — Registros con ID mayor y menor límite crediticio promedio:**
reúne 250 observaciones y presenta un valor promedio mayor de ID, un `Credit_Limit` más bajo, y valores apenas superiores en `Dependent_count`, `Months_on_book`, `Total_Relationship_Count`, `Contacts_Count_12_mon` y `Total_Trans_Ct`.

Esta lectura confirma que la principal partición entre grupos no responde a perfiles bancarios claramente diferenciados, sino al peso desproporcionado de ID cuando no se escala la información. Por ello, aunque el modelo **Sin Escalar** fue el mejor según el criterio automático de *silhouette*, su utilidad analítica para segmentación sustantiva es limitada.

6.7. Síntesis

El análisis de centroides con K -medias permitió comparar una configuración estándar con varias alternativas de preprocesamiento. El modelo seleccionado automáticamente fue **Sin Escalar**, con $K = 2$ y *silhouette* de 0.8640, superando ampliamente a las demás configuraciones en el criterio cuantitativo de evaluación interna.

Sin embargo, la inspección detallada de los centroides mostró que el agrupamiento estuvo fuertemente condicionado por la variable ID y por la ausencia de estandarización, de modo que la separación obtenida no refleja de forma limpia patrones de comportamiento bancario. En consecuencia, este resultado documenta correctamente el desenlace del experimento comparativo, pero también evidencia la importancia de revisar la naturaleza de las variables antes de aceptar un modelo como sustantivamente útil.

7. Análisis de T-SNE y UMAP

7.1. Configuración estándar (StandardScaler)

Se aplicaron los métodos T-SNE y UMAP sobre los datos previamente estandarizados mediante *StandardScaler*, con el objetivo de visualizar la estructura de los datos en un espacio

bidimensional.

7.1.1. T-SNE (StandardScaler)

El método T-SNE permite observar la formación de agrupaciones en función de la similitud local entre los datos. En esta configuración, se identifican regiones donde los puntos tienden a concentrarse, lo que sugiere la presencia de posibles clusters.

Sin embargo, la separación entre algunos grupos no es completamente clara, lo que indica que el método puede verse afectado por ruido o por la alta dimensionalidad original de los datos.




Figura 20: T-SNE Standard

7.1.2. UMAP (StandardScaler)

UMAP muestra una estructura más organizada en comparación con T-SNE. Se observan agrupaciones con mayor continuidad y mejor distribución global de los datos.

Este método logra preservar tanto la estructura local como global, lo que permite identificar patrones de agrupamiento con mayor claridad.




Figura 21: UMAP Standard

7.2. Variación con RobustScaler

Se aplicaron T-SNE y UMAP utilizando *RobustScaler*, el cual reduce el impacto de valores atípicos en los datos.

7.2.1. T-SNE (RobustScaler)

En esta configuración, T-SNE muestra una mejora en la compactación de los grupos. Los puntos presentan una mayor cohesión dentro de cada cluster, lo que sugiere una mejor representación de las similitudes entre observaciones.

Aun así, pueden existir zonas donde los clusters no estén completamente separados.




Figura 22: T-SNE robust

7.2.2. UMAP (RobustScaler)

UMAP presenta una mejora significativa en la definición de los grupos. Se observan clusters más compactos y mejor separados en comparación con la configuración estándar.

Esto indica que el uso de *RobustScaler* contribuye a una representación más fiel de la estructura de los datos cuando existen valores atípicos.




Figura 23: UMAP Robust

7.3. Aplicación sobre ACP

Se aplicaron T-SNE y UMAP sobre los datos transformados mediante Análisis de Componentes Principales (ACP), utilizando las componentes principales previamente seleccionadas.

7.3.1. T-SNE (sobre ACP)

Al trabajar con datos reducidos en dimensionalidad, T-SNE logra una representación más clara de los clusters. Se observan agrupaciones mejor definidas y con menor dispersión interna.

La reducción de ruido y redundancia permite que el algoritmo capture de manera más efectiva las relaciones entre los datos.




Figura 24: T-SNE sobre ACP

7.3.2. UMAP (sobre ACP)

UMAP sobre ACP presenta la mejor estructura visual entre todas las configuraciones evaluadas. Los clusters aparecen claramente separados y con alta cohesión interna.

Este resultado evidencia que la combinación de reducción de dimensionalidad (ACP) y técnicas de proyección no lineal (UMAP) permite obtener una representación óptima de los datos.




Figura 25: UMAP sobre ACP

7.4. Selección del mejor modelo

Comparando todas las configuraciones evaluadas:

- T-SNE (StandardScaler)
- UMAP (StandardScaler)
- T-SNE (RobustScaler)
- UMAP (RobustScaler)
- T-SNE (ACP)
- UMAP (ACP)

Se determina que el mejor modelo corresponde a:

UMAP aplicado sobre datos transformados mediante ACP

Esto se debe a que presenta:

- Mejor separación entre clusters
 - Mayor compactación de los grupos
 - Estructura global más clara
-

7.5. Síntesis

El análisis mediante T-SNE y UMAP permitió visualizar la estructura de los datos en un espacio bidimensional, facilitando la identificación de patrones y agrupaciones.

Se concluye que:

- UMAP ofrece una representación más estable y estructurada que T-SNE.
- El uso de *RobustScaler* mejora la calidad de las visualizaciones.
- La combinación de ACP con UMAP produce los mejores resultados, al reducir la dimensionalidad y eliminar ruido en los datos.

8. Referencias

- Demšar, U., Harris, P., Brunsdon, C., Fotheringham, A. S., & McLoone, S. (2013). Principal component analysis on spatial data: An overview. *Annals of the Association of American Geographers*, 103(1), 106–128.
- Dhulipala, L., Eisenstat, D., Łącki, J., Mirrokni, V., & Shi, J. (2021). Hierarchical agglomerative graph clustering in nearly-linear time. *Proceedings of the 38th International Conference on Machine Learning*, 139, 2885–2895.
- Dutta Roy, D. (2010). Cluster analysis for test-retest reliability. *International Journal of Psychological Research*, 3(1), 131–139.
- Lozares Colina, C., & López Roldán, P. (1991). El análisis de componentes principales: Aplicación al análisis de datos secundarios. *Papers: Revista de Sociologia*, 37, 31–63.
- Montano Rivas, J. A., & Juárez Cerrillo, S. F. (2014). Un algoritmo genético para selección de kernel en análisis de componentes principales con kernels. *Revista Investigación Operacional*, 35(2), 148–156.

- Munandar, T. A., & Handayani, D. (2023). Data mining for development inequality. *IAENG International Journal of Applied Mathematics*, 53(2), 646–655.
- Rodríguez, J. C., Del Portillo Z., D., & Sánchez Torres, G. (2010). Interpolation centers' selection using hierarchical curvature-based clustering. *Revista Ingenierías Universidad de Medellín*, 9(17), 131–138.
- Sosa, J., & Aristizabal, J.-P. (2022). Some developments in Bayesian hierarchical linear regression modeling. *Revista Colombiana de Estadística - Applied Statistics*, 45(2), 231–255. <https://doi.org/10.15446/rce.v45n2.98988>
- Valdés García, D., Reyes Chirino, R., Jaime Infante, R. A., Figueroa Cabrera, E., & Suárez Hernández, J. A. (2021). Método de clustering jerárquico aglomerativo para la asignación del financiamiento a proyectos de desarrollo local. *Revista Cubana de Transformación Digital*, 2(2), 71–83.